Introducción Sólida al Machine Learning

1. ¿Qué es el Machine Learning?

El **Machine Learning (Aprendizaje Automático)** es una rama de la inteligencia artificial en la que las computadoras aprenden patrones a partir de datos históricos para hacer predicciones o tomar decisiones sin haber sido programadas explícitamente con reglas paso a paso.

Fundamentos Teóricos

En esencia, el Machine Learning se apoya en tres pilares matemáticos:

- **Aproximación de Funciones:** En términos matemáticos, un modelo de ML intenta encontrar una función objetivo desconocida f que relacione las variables de entrada (X) con una salida (y), expresada como $y = f(X) + \epsilon$, donde ϵ representa el ruido aleatorio irreducible.
- **Funciones de Pérdida y Optimización:** Un modelo mide qué tan equivocadas son sus predicciones mediante una **función de pérdida** (como el Error Cuadrático Medio o la Entropía Cruzada). Mejora utilizando algoritmos de optimización —principalmente el **Descenso del Gradiente**— para ajustar iterativamente sus parámetros internos (pesos) y minimizar ese error.
- **Generalización:** El objetivo teórico final del ML no es solo memorizar ejemplos pasados, sino **generalizar** bien ante datos futuros nunca vistos. Esto requiere equilibrar el **Sesgo (Bias)** (error por suposiciones demasiado simples) y la **Varianza (Variance)** (error por sensibilidad excesiva a pequeñas fluctuaciones en los datos de entrenamiento).

---

2. Los Tres Tipos Principales de Machine Learning

Tipo	Cómo Aprende	Casos de Uso Comunes
Aprendizaje Supervisado	Aprende de datos etiquetados donde se proporcionan tanto las entradas (X) como las respuestas correctas (y).	Predicción de precios de acciones, detección de spam, diagnóstico médico.
Aprendizaje No Supervisado	Encuentra patrones ocultos o agrupaciones en datos sin etiquetar (solo X) y sin respuestas predefinidas.	Segmentación de clientes, detección de anomalías, agrupación de activos similares.
Aprendizaje por Refuerzo	Aprende mediante prueba y error realizando acciones en un entorno para maximizar recompensas acumuladas.	Bots de trading algorítmico, robótica, IA para videojuegos.

---

3. Aprendizaje Supervisado vs. No Supervisado: ¿Cuándo Usar Cada Uno?

La elección entre aprendizaje supervisado y no supervisado depende principalmente de la **estructura de los datos** y del **objetivo del problema**.

Usa Aprendizaje Supervisado Cuando:

- **Tienes etiquetas históricas:** Tu conjunto de datos ya contiene resultados conocidos (por ejemplo, impagos de crédito pasados, retornos históricos de activos o casos de fraude etiquetados).
- **Quieres predecir un resultado específico:** Tu objetivo es pronosticar un número (**Regresión**) o asignar una categoría conocida (**Clasificación**).
- **Necesitas métricas claras de precisión:** Como existen respuestas verdaderas en tu conjunto de prueba, puedes medir objetivamente el rendimiento con métricas como R-cuadrado, Exactitud (Accuracy), Precisión o Exhaustividad (Recall).
- **Ejemplo:** Usar `Volatility`, `Beta` y `Momentum` para predecir si el `Annual_Return` de una acción el próximo año será positivo o negativo.

Usa Aprendizaje No Supervisado Cuando:

- **Tus datos no están etiquetados:** Tienes variables de entrada, pero ninguna columna con la "respuesta correcta" histórica para entrenar (y etiquetar manualmente es muy costoso o imposible).
- **Tu objetivo es explorar y descubrir estructuras:** Quieres descubrir segmentos ocultos, comprimir conjuntos de datos complejos o detectar valores atípicos (outliers) sin reglas predefinidas.
- **Estás preparando datos para tareas posteriores:** Técnicas no supervisadas como el Análisis de Componentes Principales (PCA) permiten reducir docenas de variables correlacionadas en unas pocas características limpias antes de alimentar un modelo supervisado.
- **Ejemplo:** Agrupar 500 acciones en clústeres naturales según su perfil de riesgo usando `Volatility` y `Max_Drawdown`, sin indicarle de antemano al algoritmo cuántos niveles de riesgo existen.

Matriz Rápida de Decisión

Criterio	Aprendizaje Supervisado	Aprendizaje No Supervisado
Variable Objetivo (y)	Presente y conocida	Ausente o desconocida
Objetivo Principal	Predicción y pronóstico	Descubrimiento de patrones y agrupación
Esfuerzo Humano Inicial	Alto (requiere datos etiquetados limpios)	Bajo (trabaja directo con variables crudas)
Evaluación	Comparación directa contra la verdad real	Indirecta (cohesión de clústeres, revisión experta)

---

4. Tareas Principales Dentro del Aprendizaje Supervisado

La mayoría de los modelos prácticos de ML en negocios y finanzas se dividen en dos categorías:

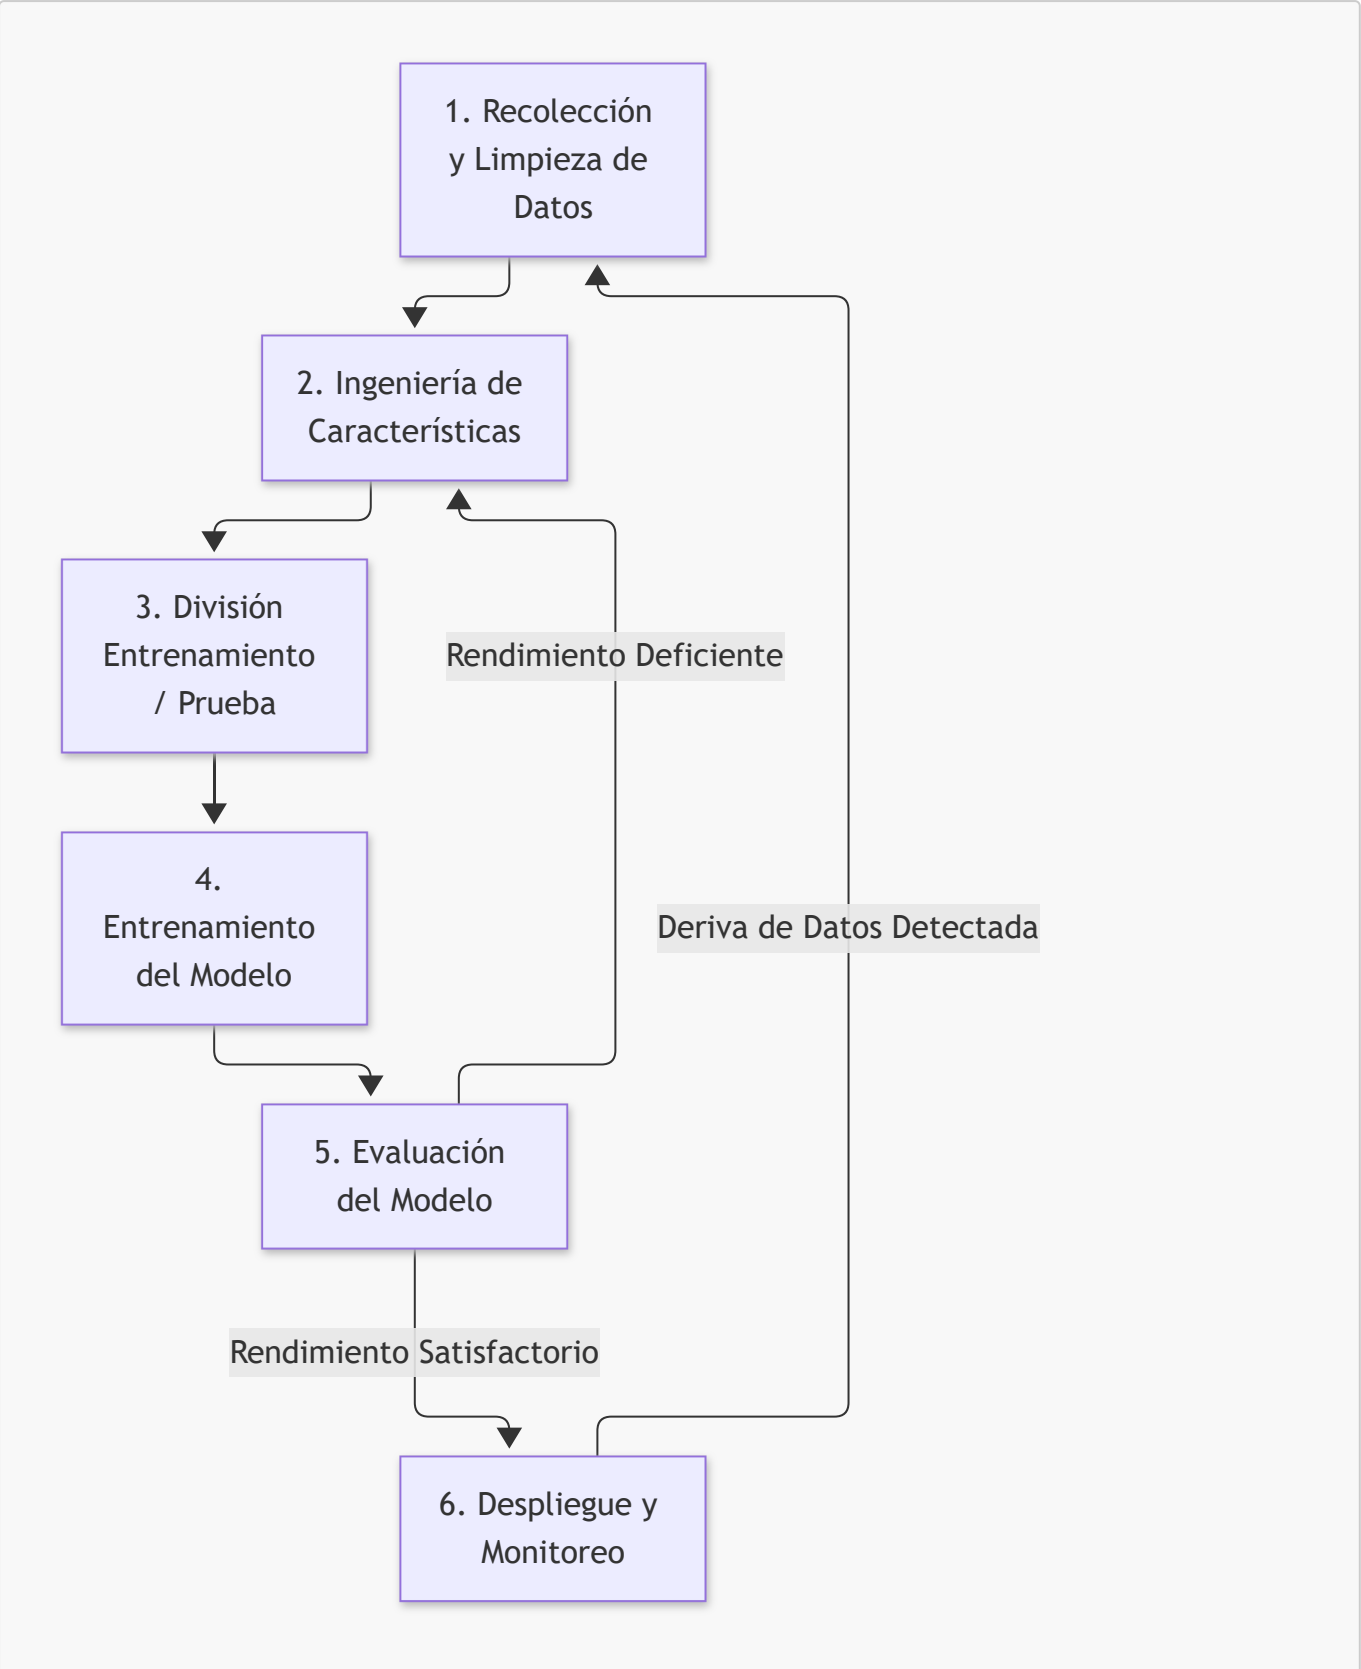
- **Regresión:** Predice un valor numérico continuo. Por ejemplo, pronosticar el precio de un activo mañana o estimar su retorno anual.
- **Clasificación:** Predice una categoría o etiqueta discreta. Por ejemplo, decidir si una transacción es fraudulenta o legítima, o si una acción subirá o bajará.

---

5. El Flujo de Trabajo Estándar en Machine Learning

Construir un modelo de ML sigue un proceso iterativo y repetible desde los datos sin procesar hasta su despliegue en el mundo real.

Diagrama de Flujo



Desglose Paso a Paso

- **1. Recolección y Limpieza de Datos:** Reunir datos crudos y corregir valores faltantes, duplicados o valores atípicos. Tener datos limpios importa mucho más que usar algoritmos complejos.
- **2. Ingeniería de Características (Feature Engineering):** Seleccionar y transformar variables crudas (como convertir precios diarios en `Volatility` o `Momentum`) para que el modelo detecte patrones con

mayor facilidad.

- **3. División Entrenamiento / Prueba (Train/Test Split):** Dividir los datos en un conjunto de entrenamiento (usualmente 70–80%) para enseñar al modelo, y un conjunto de prueba (20–30%) para evaluarlo con datos no vistos sin fuga de información.
- **4. Entrenamiento del Modelo:** Alimentar un algoritmo (como Regresión Lineal, Random Forest o Redes Neuronales) con los datos de entrenamiento para encontrar los parámetros matemáticos óptimos.
- **5. Evaluación del Modelo:** Medir la precisión en el conjunto de prueba usando métricas adecuadas para la tarea, como el Error Cuadrático Medio para regresión o Precisión y Recall para clasificación. Si el rendimiento es bajo, se regresa a la Ingeniería de Características o se ajustan los hiperparámetros.
- **6. Despliegue y Monitoreo:** Poner el modelo en producción y supervisarlo a lo largo del tiempo para detectar pérdida de rendimiento conforme cambian los datos del mundo real.

---

6. Conceptos Teóricos Clave para Conocer Desde el Principio

- **Sobreajuste vs. Subajuste (Overfitting vs. Underfitting):** El sobreajuste ocurre cuando un modelo memoriza el ruido aleatorio de los datos de entrenamiento y falla con datos nuevos (alta varianza). El subajuste ocurre cuando un modelo es demasiado simple para capturar la tendencia subyacente (alto sesgo).
- **Características (X) vs. Objetivo (y):** Las características son las variables de entrada usadas para predecir. El objetivo es el resultado específico que deseas predecir.
- **Fuga de Datos (Data Leakage):** Permitir accidentalmente que información del conjunto de prueba —o datos del futuro— se filtre en el proceso de entrenamiento, generando métricas artificialmente altas que luego fallan en entornos reales.